

Zukünftige Börsenprognose (RNN oder CNN)

Zeynep Sena Karabacak

Informatik – TDU

e160503110@stud.tau.edu.tr

Github: <https://github.com/zeynepsenak/Stockprediction-CNN-RNN->

(RNN kodu çalışıyor CNN kısmı henüz tam değil)

Abstract

Die Börsenprognose ist ein bedeutendes Thema in unserem Leben. Wissenschaft und Technologie entwickeln sich, damit es einfacher sein wird, den Aktienmarkt mithilfe von maschinellem Lernen, eingehendem Lernen und verschiedenen Lernmethoden vorherzusagen. Aufgrund der steigenden Inflation in der Welt, ist es noch wichtiger.[1]

Für die Schätzungen der Kursbewegungen an der Börse werden meistens das Recurrent Neural Network (RNN) verwendet. Es gibt aber auch Versuche mit der Convolutional Neural Network.[2][3] Die Idee, Zahlen zu visualisieren und dann neue visuelle Datensätze zu erstellen, ist interessant. Aber hat CNN gut Ergebnisse für die Aktienprognose? Sollten wir den Hauptweg gehen, der RNN ist, oder CNN versuchen.


In diesem Artikel geht es um Aktienprognose mit CNN und RNN. Als Eingabe werden wir aus der Internet dem Eröffnungspreis, dem hohen Preis, dem niedrigen Preis, dem Schlusskurs und dem Aktienvolumen nehmen und es mit CNN und RNN testen. Als Ergebnis werden wir die Vor- und Nachteile der beiden untersuchen.

1. Einleitung

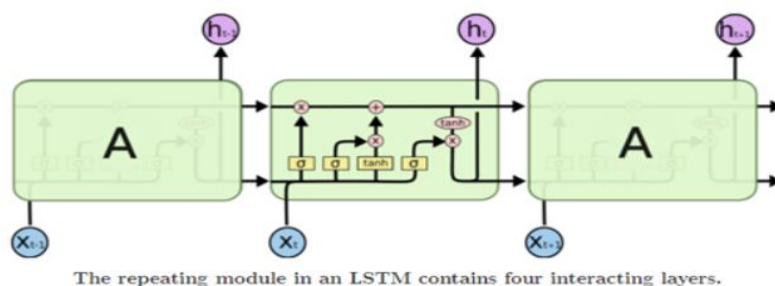
Wirtschaft ist wichtig für Länder, Unternehmen und Einzelpersonen. Aber Finanzindikatoren sind so kompliziert und auch die Fluktuation an den Aktienmärkten ist sehr gewalttätig. Die Vorhersage des Marktwerts ist von großer Bedeutung, um den Gewinn beim Kauf von Aktienoptionen zu maximieren und gleichzeitig das Risiko gering zu halten. Mit dem Fortschreiten des Maschinellen Lernens steigt jedoch die Möglichkeit, ein stetiges Vermögen an der Börse zu erzielen, und es hilft Experten, die informativsten Indikatoren für eine bessere Vorhersage herauszufinden.

Bevor beginnen lass uns die CNN und RNN Struktur kennenlernen. Feed Forward neuralem Netz Aufbau ist eine Methode, die eine Ausgabe generiert, indem mathematische Operationen auf die

Informationen angewendet werden, die von der Eingabe in Neuronen auf Schichten kommen. Im Gegensatz zu anderen neuronalen Netzen wertet die RNN-Struktur auch frühere Eingaben aus. Das heißt, die Ausgabe erfolgt durch Kombinieren der vorherigen und aktuellen Eingaben. Es wird dann berechnet, um die Fehlerrate mit Backpropagation (Gradient-Descent) zu reduzieren. Gradient ist der Wert, der zum Anpassen des Gewichts von Neuronen verwendet wird. In langen miteinander verbundenen Netzwerken wird jedoch die Auswirkung des Fehlers verringert, und der Gradient beginnt zu verschwinden. Dies kann es unmöglich machen, das richtige Ergebnis zu erzielen. Die Verwendung von RELU anstelle von Sigmoid oder Tanh als Aktivierungsfunktion kann als Lösung für dieses Problem gezeigt werden. Eine andere Lösung für dieses Problem ist LSTM (Long Term Short Memory). Es wurde entwickelt, um dieses Problem zu lösen.




LSTM hat vier speziell gebundene Schichten anstelle der neuronalen Schicht. Diese Schichten werden Türen genannt. Bei diesen Türen entscheidet die Zelle, was gespeichert, wann gelöscht, gelesen und geschrieben werden soll. Diese Gates haben eine Netzwerkstruktur und eine Aktivierungsfunktion. Genau wie bei Neuronen wird die eingehende Eingabe nach Gewicht weitergeleitet oder gestoppt.



Andererseits lernt und verwendet CNN die einzigartigen Eigenschaften von Objekten, um die visuellen Eingaben zu unterscheiden, die es empfängt. Dies geschieht ähnlich in unserem Gehirn. Wir nennen es ein Flugzeug, indem wir die Merkmale des Bildes betrachten, das wir betrachten, wie die zwei Flügel, den Motor und die Fenster.

Cnn macht zuvor erkennen sie Eigenschaften auf niedrigerer Ebene wie Kurven und Kanten und erstellen sie für abstraktere Konzepte. Um diese Funktionalität zu erreichen, verarbeitet Cnn das Bild mit verschiedenen Ebenen. Diese; Convolutional Layer, Non-Linearity Layer, Pooling Layer, Flattening Layer und Fully Connected Layer.



Für CNN ist die Eingabe jedoch visuell aber was wir an der Börse haben, sind viele Zahlenwerte. Wir können diese Zahlenwerte jedoch grafisch darstellen. Wir können diese Grafiken auch als visuelle Eingabe in CNN platzieren. Es gibt Studien, die sich mit dieser Idee befassen. Es ist jedoch nicht so bekannt wie RNN für die Börsenanalyse. Hier stellt sich die Frage: Kann die Visualisierung der Zahlen bessere Vorhersagen liefern?

2. Die Methodik für RNN


Hier wird das Recurrent Neuronale Netz (RNN) und das Long Short Term Memory (LSTM) berücksichtigt. Metodologie:

In der ersten Phase werden Daten von Apple übernommen. [6].

| | High | Low | Open | Close | Volume | Adj Close |
|------------|------------|------------|------------|------------|-------------|------------|
| Date | | | | | | |
| 2004-01-02 | 1.553571 | 1.512857 | 1.539286 | 1.520000 | 36160600.0 | 1.315860 |
| 2004-01-05 | 1.599286 | 1.530000 | 1.530000 | 1.583571 | 98754600.0 | 1.370894 |
| 2004-01-06 | 1.601429 | 1.550714 | 1.589286 | 1.577857 | 127337000.0 | 1.365947 |
| 2004-01-07 | 1.630714 | 1.566429 | 1.578571 | 1.613571 | 146718600.0 | 1.396865 |
| 2004-01-08 | 1.695000 | 1.617857 | 1.631429 | 1.668571 | 115075800.0 | 1.444478 |
| ... | ... | ... | ... | ... | ... | ... |
| 2019-12-24 | 284.890015 | 282.920013 | 284.690002 | 284.269989 | 12119700.0 | 282.831299 |
| 2019-12-26 | 289.980011 | 284.700012 | 284.820007 | 289.910004 | 23280300.0 | 288.442780 |
| 2019-12-27 | 293.970001 | 288.119995 | 291.119995 | 289.799988 | 36566500.0 | 288.333313 |
| 2019-12-30 | 292.690002 | 285.220001 | 289.459991 | 291.519989 | 36028600.0 | 290.044617 |
| 2019-12-31 | 293.679993 | 289.519989 | 289.929993 | 293.649994 | 25201400.0 | 292.163818 |

4027 rows × 6 columns

Apple's Schlusspreisverlauf zieht von 01-01-2004 bis 01-01-2020 wieso aus:



Für zweiten Schritt habe Ich die Trainingsdaten als die ersten 0,8 aller Daten festgelegt. Dann habe ich die Daten im Bereich 0-1 skaliert.

Und für die nächste Stufe werden die Daten in x_train und y_train aufgeteilt. Für alle 60 haben wir Eingaben in x_train und für die Ausgaben 61st in y_train gemacht. Und dann werden sie in ein numpy Array konvertiert. Und das erste 61-teilige Datensatz sieht wieso aus (Erste 60 in x_train und 61st in y_train) :

```
[array([0.00000000, 0.00021761, 0.00019805, 0.00032031, 0.00050858,
        0.00042056, 0.00059905, 0.00069441, 0.00071397, 0.00038388,
        0.00035209, 0.00035454, 0.0003252 , 0.00022006, 0.00031297,
        0.000423  , 0.00043767, 0.00030319, 0.00034231, 0.00031297,
        0.00025429, 0.00023962, 0.0001247 , 0.00027874, 0.00034965,
        0.00033987, 0.00041567, 0.00061616, 0.00059905, 0.00042056,
        0.00045968, 0.00048413, 0.00029097, 0.00027385, 0.0002225 ,
        0.00026407, 0.0003741 , 0.00043034, 0.00064551, 0.00066996,
        0.00061861, 0.00064551, 0.0009487 , 0.00133502, 0.00115408,
        0.00142305, 0.00156486, 0.00143527, 0.00153552, 0.00126411,
        0.00111007, 0.00120054, 0.0010734 , 0.00111985, 0.00111985,
        0.00098048, 0.00103183, 0.00136681, 0.00140837, 0.0016211 ])]
[0.0016235433938904783]
```

Dann habe ich Modell gebaut. Es hat 2 Schichten mit 50 Neuronen und 2 Dense Schichte. Erste Dense Schichten hat 25 Neuronen und zweite hat 1 Neuron.

Danach Modell wird mit dem Optimierer 'adam' trainiert. Adam ist eine Kombination aus RMSprop und stochastischem Gradientenabstieg mit Impuls betrachtet werden. Es verwendet die quadratischen Gradienten, um die Lernrate wie RMSprop zu skalieren, und nutzt den Impuls, indem es den gleitenden Durchschnitt des Gradienten anstelle des Gradienten selbst wie SGD mit Impuls verwendet. Und Verlust wird mit rmse (Root Mean Square Error) berechnet.

Modell sieht wieso aus:

```
Model: "sequential_3"
Layer (type)                Output Shape              Param #
=====
lstm_7 (LSTM)                (None, 60, 50)           10400
lstm_8 (LSTM)                (None, 50)               20200
dense_5 (Dense)              (None, 25)               1275
dense_6 (Dense)              (None, 1)                26
=====
Total params: 31,901
Trainable params: 31,901
Non-trainable params: 0
```


Dann wird die test-Daten geprüft und dann habe ich als Ergebnis für unterschiedliche epoches und batch-sizes diese Grafiken.

Für batch size: 4, epoch: 7

2019-12-30 291.519989 279.247284

RMSE-Wert : 3.590120342682842

2019-12-31 293.649994 281.705811




2019-12-30 291.519989 242.379822

Für batch size: 1, epoch: 300

2019-12-31 293.649994 243.164108


RMSE-Wert : 11.687409314722181



Für batch size: 32, epoch: 100

RMSE-Wert : 7.025421235846431

| | | |
|------------|------------|------------|
| 2019-12-30 | 291.519989 | 267.852936 |
| 2019-12-31 | 293.649994 | 269.168365 |




Das beste Ergebnis war Epoche: 7 und Batch-Size: 1. RMSE für diese Werte ist 3.59. Das ist nicht perfekt aber auch nicht schlecht.

3. Die Methodik für CNN

Börsenprognose für CNN habe ich zwei Wege probiert.

Die erste Methode, mit der ich versucht habe, die Zahlen zu visualisieren, besteht darin, die Abschlussdaten der letzten 60 Tage aufzuzeichnen und das Diagramm zu speichern. Es gibt Diagramme mit blauen Linien, und für jedes Bild wurden 120 Tage zuvor Daten geschlossen. Und es gibt die Ausgabe von Tag 61, die jeder visuellen Eingabe entspricht.



Beispiele Eingabe ist:

und die Ausgabe: 293.649994

Aber es nie funktioniert hat.

Die zweite Methode, die ich versuchte, bestand darin, die Daten der letzten 120 Tage in ein Numpy-Array zu konvertieren und das resultierende Array in ein visuelles zu konvertieren. Das resultierende Bild ist unten.



Und die Ausgabe ist: 293.64994

Aber diese Methode auch funktioniert nicht.

4.Abschluss

5.Related works

Stock Prediction using Convolutional Neural Network[2]

Convolutional Networks for Stock Trading[3]

Vorhersage von Aktienkursen mit LSTM[4]

Stock Market Index Prediction with artificial neural networks[5]

6.Datasets

Yahoo - Apple Stock[6]

Yahoo – Google Stock[7]

7. Verweise

1. <https://www.statista.com/statistics/256598/global-inflation-rate-compared-to-previous-year/>
2. https://www.researchgate.net/publication/328754813_Stock_Prediction_Using_Convolutional_Neural_Network
3. <https://pdfs.semanticscholar.org/86af/cb8f6c9e182d79a25071371e6b567619b6dc.pdf>
4. https://www.researchgate.net/publication/327967988_Predicting_Stock_Prices_Using_LSTM
5. <http://www.acarindex.com/dosyalar/makale/acarindex-1423905602.pdf>
6. <https://finance.yahoo.com/quote/AAPL?p=AAPL>
7. <https://finance.yahoo.com/quote/GOOGL%3B/>